

Modelos de Crédito

Mayo 13, 2026

Mónica Valeria Jáuregui Rodríguez
Ingeniería Financiera
ITESO
Guadalajara, México
monica.jauregui@iteso.mx

Mariana Ripoll
Ingeniería Financiera
ITESO
Guadalajara, México
mariana.ripoll@iteso.mx

Sofía Vazquez Guerrero
Ingeniería Financiera
ITESO
Guadalajara, México
sofia.vazquez@iteso.mx

Ricardo Ibarra Talamantes
Ingeniería Financiera
ITESO
Guadalajara, México
Ricardo.ibarra@iteso.mx

Alberto Marin Gomez
Ingeniería Financiera
ITESO
Guadalajara, México
alberto.marin@iteso.mx

Luis Fernando Ramirez Lopez
Ingeniería Financiera
ITESO
Guadalajara, México
lf728831@iteso.mx

Abstracto— texto

El presente trabajo desarrolla un modelo matemático-financiero implementado en Python para el financiamiento de cirugías plásticas electivas en la Zona Metropolitana de Guadalajara, México. El modelo estima la Probabilidad de Incumplimiento (PD) mediante Regresión Logística y Random Forest, la Pérdida Dado el Incumplimiento (LGD) a través de Ridge Regression y Random Forest Regressor, y calcula la Pérdida Esperada bajo el marco de Basilea II ($EL = PD \times LGD \times EAD$), entrenado sobre 95,269 préstamos del dataset LendingClub (2007–2015). Ambos modelos PD alcanzaron un AUC de 0.8587 y un Gini de 0.7175, consistentes con los benchmarks de la industria. El sistema asigna tasas diferenciadas por grade crediticio (10.4%–32.7%) con un ajuste de +3.5 puntos porcentuales por prima país México, e integra un seguro de vida proporcional al monto (prima 1.5%) que extingue el saldo insoluto ante fallecimiento del acreditado. Una simulación masiva de 10,000 solicitudes arrojó un profit neto de \$3,530,740 USD, un ROE de 14.58% y una tasa de mora efectiva de 3.6%, inferior al benchmark nacional de 4.5%.

I. INTRODUCCIÓN

En los últimos años, la cirugía plástica ha experimentado un crecimiento sostenido en México. De acuerdo con datos de la ISAPS (2026), en 2024 se realizaron aproximadamente 1,294,946 procedimientos estéticos en el país, posicionando a México como el sexto mercado mundial en este sector, con un incremento del 42.5% en los últimos cuatro años. Este dinamismo se ve amplificado por el turismo médico, dado que los costos en México pueden ser entre 50% y 80% menores que en Estados Unidos, convirtiendo a ciudades como Guadalajara en destinos quirúrgicos relevantes.

A pesar de este crecimiento, los seguros de gastos médicos mayores excluyen sistemáticamente los procedimientos estéticos de su cobertura, obligando al paciente a asumir la totalidad del costo de forma directa. Aunque existen algunas

opciones de financiamiento en el mercado, como operadores como Alivio Capital, Mend y Kueski, estas operan bajo esquemas de crédito personal genérico, sin una estructura matemática que contemple las particularidades del riesgo asociado a este tipo de operación.

El presente proyecto tiene por objeto el desarrollo de un modelo matemático-financiero implementado en Python para el financiamiento de cirugías plásticas en la Zona Metropolitana de Guadalajara. El esquema operativo consiste en que el acreditado solicita el financiamiento, la institución desembolsa el monto directamente al hospital o médico de elección, y el acreditado liquida la deuda mediante pagos periódicos con intereses bajo un esquema de amortización de cuota fija. Desde el punto de vista técnico, el modelo integra tres componentes fundamentales del marco Basilea II: la estimación de la Probabilidad de Incumplimiento (PD) mediante Regresión Logística y Random Forest, la modelación de la Pérdida Dado el Incumplimiento (LGD) a través de Ridge Regression y Random Forest Regressor, y el cálculo de la Pérdida Esperada ($EL = PD \times LGD \times EAD$). Estos componentes se articulan con la valuación actuarial de un seguro de vida vinculado a cada operación, cuya función es extinguir el saldo insoluto en caso de fallecimiento del acreditado durante el procedimiento quirúrgico, constituyendo así el aporte técnico central del trabajo

Entre 2014 y 2025 se documentaron al menos 121 fallecimientos por cirugías estéticas en México, con un máximo de 22 casos en 2023 (Animal Político/CONNECTAS, 2026), lo que justifica tratar el riesgo de fallecimiento como una variable actuarial formal dentro del modelo. En caso de que este evento ocurra, la aseguradora liquida el saldo insoluto, extinguendo la obligación crediticia.

II. MODELO DE CRÉDITO EN PYTHON

A. Metodología

Para construir el modelo se usó un proceso estándar de evaluación de riesgo crediticio. Primero se define quién es un "mal pagador": se etiqueta como default (1) a cualquier préstamo que terminó en incumplimiento, ya sea por mora severa, gracia o castigo contable, y como buen pagador (0) a quienes liquidaron completamente su deuda. La pérdida en caso de default se calcula como la proporción del préstamo que no se recuperó.

Se probaron dos modelos para predecir si una persona va a incumplir: una Regresión Logística, que es el modelo más transparente e interpretable, y un Random Forest, que captura relaciones más complejas entre variables. Ambos se configuraron para tratar por igual a buenos y malos pagadores, ya que en cualquier cartera de crédito real los incumplimientos son minoría, en este caso el 22.2%, y sin ese ajuste el modelo simplemente ignoraría esa clase.

B. Diseño de Modelo y Diagrama

El dataset proviene de LendingClub, una plataforma de préstamos personales de Estados Unidos del periodo 2007–2015. Se eligió este dataset porque sus préstamos de consolidación de tarjeta de crédito comparten la misma estructura que un crédito para cirugía estética: sin garantía, plazo fijo y pagos mensuales. Del archivo original de 249,343 registros se filtraron únicamente los préstamos con resultado conocido, quedando una muestra de 95,269 préstamos para entrenar el modelo de PD.

Antes de entrenar, los datos se limpiaron: se extrajeron los valores numéricos de campos como el plazo y la antigüedad laboral, se calculó cuántos años de historial crediticio tiene cada persona, se rellenaron los valores faltantes con la mediana o con un indicador de "sin actividad", y se convirtieron las variables categóricas como el grade o el tipo de vivienda en columnas numéricas. El resultado final fue un dataset de 76 variables sin ningún valor nulo, dividido en 80% para entrenar el modelo y 20% para probarlo, respetando la proporción de defaults en ambos grupos.

El modelo se estructura como un pipeline modular de 4 etapas secuenciales, cada una implementada en funciones independientes que pueden ejecutarse, auditarse y modificarse de forma aislada.




Figura 1. Diagrama lógico del pipeline de riesgo crediticio

A partir del archivo preprocesado de 249,343 registros, se filtran únicamente los préstamos con estado terminal conocido, es decir, los denominados como *Fully Paid* y *Charged Off*, junto con los estados intermedios *Late (31-120 days)*, "*Late (16-30 days)*", *In Grace Period* y *Default*, resultando en 95,269 observaciones. Los préstamos con estatus *Current* se excluyen por carecer de un resultado final observable. La variable objetivo para PD se codifica como binaria: 0 para pagos completos, 1 para cualquier forma de incumplimiento. Para LGD, se calcula sobre el subconjunto de 21,159 préstamos en default como $LGD = 1 - (\text{recuperaciones} / \text{monto fondeado})$, acotado entre 0 y 1. La separación de los datasets de PD y LGD garantiza que cada componente de la pérdida esperada se modele con la muestra que le corresponde, sin contaminación cruzada.




Figura 2. Variables con mayor poder predictivo según el modelo Random Forest PD, ordenadas por importancia relativa.

La segunda etapa es la transformación de variables. El campo *term* se convierte de texto a entero (36 o 60 meses), *emp_length* se mapea a una escala ordinal de 0 a 10 años, y *earliest_cr_line* se transforma en antigüedad crediticia medida en años respecto a la fecha de emisión del préstamo. Los valores nulos en variables de morosidad histórica (*mths_since_last_delinq*, *mths_since_last_record*) se imputan con -1, interpretado como "evento nunca ocurrido", mientras que las variables numéricas restantes se imputan con la mediana del campo. Las variables categóricas como *grade*, *sub_grade*, *home_ownership* y *verification_status*, se codifican mediante One-Hot Encoding con eliminación de la primera categoría para evitar colinealidad. El dataset resultante contiene 76 variables numéricas sin valores faltantes.

La tercera etapa comprende el entrenamiento y evaluación de modelos. Para la estimación de PD se entrenan dos clasificadores: una Regresión Logística con regularización L2 (*solver* LBFGS, 1,000 iteraciones máximas) y un Random Forest con 200 árboles, profundidad máxima de 10 y mínimo de 50 observaciones por hoja terminal. Ambos modelos utilizan el parámetro *class_weight='balanced'* para compensar la proporción 78:22 entre buenos pagadores y defaults. Las features se escalan con *StandardScaler* únicamente para la Regresión Logística, dado que los modelos de ensamble basados en árboles son invariantes a la escala de las variables. La evaluación se realiza sobre el conjunto de prueba (20% de los datos, estratificado) y se complementa con validación cruzada estratificada de 5 pliegues sobre el conjunto de entrenamiento para verificar la estabilidad del modelo.




Figura 3. Matriz de confusión del modelo Random Forest PD (umbral = 0.5) y métricas de negocio asociadas sobre el conjunto de prueba ($n = 19,054$). La especificidad del 90.8% indica que el modelo identifica correctamente a la gran mayoría de buenos pagadores, minimizando el rechazo de clientes viables.

Para la estimación de LGD se entrenan dos regresores: Ridge Regression con parámetro de regularización $\alpha = 1.0$ y un Random Forest Regressor con 200 árboles y profundidad máxima de 8. Las predicciones se acotan al intervalo $[0, 1]$ mediante la función *clip*. La distribución del LGD en el portafolio presenta una fuerte concentración en 1.0 (pérdida total), lo cual es una característica estructural del crédito al consumo no garantizado: cuando un deudor incumple un

préstamo sin colateral, la tasa de recuperación es muy baja. Ante esta concentración, el R^2 de los modelos LGD resulta prácticamente nulo, lo cual no constituye una deficiencia del modelo sino un reflejo fiel de la realidad del portafolio. En consecuencia, se adopta el LGD promedio observado del portafolio como proxy para el cálculo de EL.

La cuarta etapa es el cálculo de la Pérdida Esperada conforme al marco de Basilea II:

$$EL = PD * LGD * EAD$$

donde PD es la probabilidad predicha por el modelo Random Forest para cada préstamo, LGD es el promedio observado del portafolio de defaults, y EAD es el monto fondeado (*funded_amnt*) como proxy del saldo expuesto al momento del incumplimiento. Esta formulación asume independencia entre los tres componentes, supuesto estándar en la regulación bancaria.

C. Herramientas y fuentes de datos

El desarrollo se realizó íntegramente en Python 3.10 utilizando Jupyter Notebook como entorno de desarrollo interactivo. Las librerías principales son: *pandas* para manipulación tabular, *numpy* para cálculo numérico, *scikit-learn* para entrenamiento de modelos y métricas de evaluación, *matplotlib* y *seaborn* para visualización. El dataset proviene de LendingClub a través de Kaggle (Lending Club Loan Data, publicado por Adarsh Singh), filtrado por propósito *credit_card* para mantener coherencia con el producto de crédito analizado. Los precios de las cirugías fueron proporcionados por consulta directa con un cirujano plástico certificado de la Zona Metropolitana de Guadalajara.

D. Parámetros financieros del producto

El diseño del producto crediticio incorpora cuatro fuentes de ingreso y dos componentes de costo que determinan la viabilidad financiera de la operación.

La primera y principal fuente de ingreso es el cobro de intereses sobre los créditos que se liquidan en su totalidad, calculados mediante la fórmula de anualidad con cuota fija a 12 meses. La segunda es la comisión de apertura del 2% sobre el monto del crédito, cobrada al momento del desembolso y que se materializa antes de que exista cualquier exposición al riesgo de incumplimiento. La tercera fuente es la recuperación parcial de los créditos en default: un acreditado que incumple en el mes 8 de 12 ya realizó 7 pagos que incluyen tanto principal como intereses. La simulación modela este comportamiento asignando a cada default un porcentaje de pago aleatorio entre 30% y 70% del monto total, consistente con la evidencia empírica de que la mayoría de los incumplimientos en crédito al consumo no son inmediatos sino graduales. La cuarta fuente es el diferencial de tasas por grade: al asignar tasas más altas a perfiles de mayor riesgo (10.4% para grade A, 22.1% para grade D), el modelo cobra una prima proporcional al riesgo asumido, lo cual permite que los créditos de bajo riesgo subsidien parcialmente las pérdidas de los segmentos más riesgosos.

En cuanto a los componentes de costo, el primero es la pérdida bruta por incumplimiento, mitigada parcialmente por la recuperación descrita arriba. El segundo es el seguro de vida, estructurado como una prima proporcional del 1.5% sobre el monto del crédito. La decisión de utilizar una prima proporcional en lugar de un monto fijo obedece a una lógica actuarial: el riesgo que asume la aseguradora es directamente proporcional al monto del crédito, por lo que la prima debe serlo también.

Las tasas base del modelo provienen de LendingClub, cuya estructura de pricing refleja el costo del dinero en Estados Unidos (Federal Funds Rate de 0.25%–2.50% durante 2015–2018). Para contextualizar el producto en el mercado mexicano, se aplica un ajuste de +3.5 puntos porcentuales a cada tasa, correspondiente al diferencial histórico entre la TIIE y la Fed Funds Rate durante el periodo del dataset. Este ajuste refleja el costo de oportunidad real del capital en México y es consistente con la práctica de las instituciones financieras mexicanas que operan con spreads superiores a los observados en mercados desarrollados (Banco de México; Federal Reserve).

III. RESULTADOS Y VALIDACIÓN

A. Desempeño del Modelo PD

Ambos clasificadores entrenados para la estimación de la Probabilidad de Default obtuvieron un desempeño equivalente sobre el conjunto de prueba (19,054 observaciones). La Regresión Logística alcanzó un AUC de 0.8587, un coeficiente de Gini de 0.7175 y un estadístico KS de 0.5590. El Random Forest registró AUC de 0.8587, Gini de 0.7174 y KS de 0.5549. La validación cruzada estratificada de 5 pliegues confirmó la estabilidad de ambos modelos: la Regresión Logística obtuvo un AUC medio de 0.8575 ± 0.0027 y el Random Forest de 0.8561 ± 0.0019 , varianzas que descartan sobreajuste. Los resultados detallados se presentan en la Tabla 3.

La convergencia de ambos modelos hacia un AUC idéntico de 0.8587 sugiere que el dataset ha alcanzado su límite natural de predictibilidad: la información disponible sobre el solicitante explica todo lo que es posible explicar sobre su comportamiento de pago, y añadir complejidad algorítmica no produce ganancia discriminante adicional. Este fenómeno es consistente con la literatura sobre modelos de scoring en crédito al consumo no garantizado, donde la señal predictiva está concentrada en pocas variables macroeconómicas e históricas. Por esta razón, se privilegia la Regresión Logística para el scoring individual por su interpretabilidad regulatoria, mientras que el Random Forest se utiliza para el cálculo de la Pérdida Esperada a nivel de portafolio.




Figura 4. Curva ROC de los modelos Regresión Logística y Random Forest para la estimación de PD.

METRICAS	REG. LOGISTICA	RANDOM FOREST
DISCRIMINACIÓN (CONJUNTO DE PRUEBA)		
AUC-ROC	0.8587	0.8587
Coefficiente de Gini	0.7175	0.7174
Estadístico KS	0.5590	0.5549
CLASIFICACIÓN (UMBRAL = 0.5)		
Accuracy	0.84	0.85
Precisión — Default	0.65	0.67
Recall — Default	0.65	0.64
F1-score — Default	0.65	0.65
ESTABILIDAD (VALIDACIÓN CRUZADA 5-FOLD)		
AUC media	0.8575	0.8561
Desviación estándar	± 0.0027	± 0.0019
MODELO LGD		
RMSE	0.0840 (Ridge)	0.0841 (RF)
MAE	0.0581	0.0589
R ²	0.0100	0.0069
LGD promedio portafolio		0.9437
EL media por préstamo	\$5,679.55 USD	

B. Desempeño del Modelo LGD

Los modelos de regresión entrenados para estimar la Pérdida Dado el Incumplimiento obtuvieron un R^2 nulo en ambos casos: Ridge Regression con RMSE de 0.0840, MAE de 0.0581 y R^2 de 0.0100; Random Forest Regressor con RMSE de 0.0841, MAE de 0.0589 y R^2 de 0.0069. Este resultado no constituye una deficiencia del modelo, sino un reflejo estructural del portafolio: la distribución del LGD presenta una fuerte concentración en 1.0, con una media de 0.9437 y una mediana exacta de 1.0, característica inherente al crédito al consumo no garantizado donde la tasa de recuperación ante incumplimiento es prácticamente nula. En consecuencia, se adopta el LGD promedio observado del portafolio (0.9437) como proxy para el cálculo de la Pérdida Esperada.

C. Pérdida Esperada del Portafolio

Aplicando la fórmula $EL = PD \times LGD \times EAD$ sobre el conjunto de prueba, la Pérdida Esperada media por préstamo asciende a \$5,679.55 USD, con una Pérdida Esperada total

del portafolio de \$108,218,075 USD. La PD media predicha sobre el conjunto de prueba es de 39.17%, valor inflado respecto a la tasa real de default del 22.2% como

consecuencia del parámetro `class_weight='balanced'`, cuyo efecto sobre las probabilidades absolutas no afecta el poder discriminante del modelo pero debe considerarse antes de utilizarlas en cálculos regulatorios de capital.

Este nivel de EL media implica que, para que el portafolio sea rentable, el ingreso por intereses y comisiones por préstamo debe superar los \$5,679.55 USD de pérdida esperada, condición que el modelo verifica en la simulación masiva de la Sección IV.




Figura 5. Distribución de la Probabilidad de Default predicha (izquierda), distribución de la Pérdida Esperada por préstamo en USD (derecha)

IV. APLICACIÓN PRÁCTICA

A. Caso de Uso Específico en la Industria

El modelo se aplica al financiamiento de cirugías plásticas electivas en la Zona Metropolitana de Guadalajara, dirigido a personas físicas con capacidad de pago periódico demostrable. Los procedimientos financiables incluyen liposucción, mamoplastia, abdominoplastia, rinoplastia y blefaroplastia, con costos que en el mercado nacional oscilan entre \$27,000 y \$140,000 MXN.

El flujo operativo se desarrolla en seis pasos. Primero, el paciente selecciona un procedimiento del catálogo en la clínica asociada y manifiesta su interés en financiarlo. Segundo, la clínica captura los datos del solicitante —ingreso anual, antigüedad laboral, historial crediticio, nivel de endeudamiento y tipo de vivienda— mediante un formulario digital que alimenta directamente al modelo. Tercero, el motor de PD evalúa el perfil en tiempo real: calcula la probabilidad de incumplimiento, asigna un grade de A a G, y determina si el solicitante es aprobado (grades A–E) o rechazado (grades F–G). La evaluación toma menos de un segundo por solicitud, eliminando los tiempos de espera de 3 a 5 días hábiles que caracterizan a los procesos manuales. Cuarto, si el crédito es aprobado, el sistema genera la tabla de amortización con la tasa correspondiente al grade asignado, incluyendo el costo del seguro de vida y la comisión de apertura. Quinto, tras la firma digital del contrato, la institución desembolsa el monto directamente a la cuenta de la clínica o del cirujano, eliminando el riesgo de desvío de fondos. Sexto, el acreditado realiza sus 12 pagos mensuales mediante domiciliación bancaria o transferencia electrónica.

De manera complementaria, el modelo incorpora un seguro de vida vinculado a cada operación. El riesgo de fallecimiento

durante el procedimiento está documentado en México y justifica su tratamiento como variable actuarial formal dentro del modelo. En caso de que este evento ocurra, la aseguradora liquida el saldo insoluto, extinguiendo la obligación crediticia (Animal Político/CONNECTAS, 2026).

B. Simulación y Análisis de Resultados

La simulación se estructura en dos niveles de análisis. El primero consiste en la evaluación individual de siete perfiles de solicitantes con distintos niveles de riesgo, a quienes el modelo asigna un grado crediticio de A a G según su PD predicha, determina la tasa de interés aplicable con un ajuste de +3.5 puntos porcentuales por prima de país respecto a las tasas base de LendingClub, y genera la tabla de amortización correspondiente.

TABLA 1 — EVALUACIÓN INDIVIDUAL DE SOLICITANTES

Umbral de aprobación: PD < 30% (Grades A–E). Plazo: 12 meses.

SOLICITANTE / VARIABLE	VALOR
María López	
Procedimiento	Rinoplastia
Monto	\$80,000 MXN
PD / Grade	5% A
Tasa / Mensualidad	10.4% / \$7,048
Decisión	Aprobado
Carlos Ramírez	
Procedimiento	Liposucción y Escultura
Monto	\$120,000 MXN
PD / Grade	12% B
Tasa / Mensualidad	13.9% / \$10,769
Decisión	Aprobado
Ana Torres	
Procedimiento	Aumento de Busto
Monto	\$85,000 MXN
PD / Grade	22% C
Tasa / Mensualidad	17.6% / \$7,777
Decisión	Aprobado
Pedro Hernández	
Procedimiento	Bypass Gástrico
Monto	\$140,000 MXN
PD / Grade	38% D
Tasa / Mensualidad	22.1% / \$13,110
Decisión	Aprobado

Laura Díaz	
Procedimiento	Mommy Makeover
Monto	\$120,000 MXN
PD / Grade	52% E
Tasa / Mensualidad	26.3% / \$11,481
Decisión	Aprobado
Roberto Sánchez	

\$6,922,627 USD y un ROE de 15.54%. No obstante, operar con ese umbral implicaría asumir una proporción de riesgo considerablemente mayor, por lo que la selección del umbral definitivo depende del apetito de riesgo de la institución.

C. Impacto en Procesos Existentes

La automatización de la evaluación crediticia en Python reduce los tiempos de aprobación respecto a procesos manuales convencionales, y el esquema de pago directo al prestador elimina el riesgo moral sobre el destino de los recursos. En materia de riesgo de cartera, el índice de morosidad de préstamos personales en México se ubicó en 4.5% durante el primer semestre de 2025, cifra que funciona como benchmark para evaluar el desempeño esperado de la cartera. La integración del seguro de vida neutraliza adicionalmente el riesgo de incobrabilidad por fallecimiento, componente que los modelos de crédito al consumo genérico no contemplan (EGADE, 2025).

D. Solución de Problemas

El modelo da respuesta a tres problemas técnicos concretos. El primero es la ausencia de un sistema de scoring especializado para financiamiento de cirugías electivas: las plataformas existentes no estiman formalmente la PD del solicitante, mientras que el presente modelo la calcula mediante dos algoritmos complementarios —Regresión Logística para interpretabilidad regulatoria y Random Forest para captura de relaciones no lineales—, ambos con AUC de 0.8587, Gini de 0.72 y KS de 0.56, métricas consistentes con los benchmarks de la industria crediticia.

El segundo problema es la falta de cobertura ante el fallecimiento del acreditado durante el procedimiento: el modelo integra actuarialmente un seguro de vida proporcional al monto del crédito (prima de 1.5%), cuyo costo ya está incorporado en la estructura de costos del portafolio y cuya función es extinguir el saldo insoluto ante dicho evento. El tercer problema es la asignación de tasas uniformes en los esquemas de financiamiento existentes: el modelo resuelve esto mediante un sistema de pricing diferenciado por grade (de 10.4% para el grade A hasta 32.7% para el grade G), ajustado por una prima país de 3.5 puntos porcentuales que refleja el diferencial entre la TIIE mexicana y la tasa de referencia estadounidense sobre la que fue entrenado el modelo.

V. EVALUACIÓN DE IMPACTO

A. Estimación de Eficiencia Operativa y Rendimiento Financiero

Tiempo de aprobación. Los procesos de evaluación crediticia manual en instituciones financieras tradicionales en México toman entre 1 y 5 horas hábiles, involucrando revisión de documentos, consultas al buró de crédito y análisis por parte de un oficial de crédito. El modelo desarrollado automatiza íntegramente este proceso en

El umbral de aprobación operativo se fijó en PD < 30% (grades A–E), rechazando automáticamente los perfiles F y G por representar un riesgo de incumplimiento superior al tolerado por el modelo.

El segundo nivel consiste en una simulación masiva de 10,000 solicitudes generadas a partir de perfiles reales del dataset de LendingClub, a quienes se asignó aleatoriamente una cirugía del catálogo. El modelo aprobó 4,662 solicitudes (46.6%) y rechazó 5,338. De los acreditados aprobados, 96.4% liquidó el crédito en su totalidad, mientras que el 3.6% incurrió en incumplimiento. Los resultados financieros del portafolio simulado se resumen a continuación:

TABLA 2 — ESTADO DE RESULTADOS DEL PORTAFOLIO SIMULADO
Simulación masiva de 10,000 solicitudes. Umbral de aprobación: PD < 30%. Plazo: 12 meses.

CONCEPTO	MONTO (USD)
INGRESOS	
Intereses (acreditados que liquidaron completo)	\$3,781,398
Comisiones de apertura (2% del monto)	\$484,260
Recuperación parcial de defaults	\$470,677
EGRESOS	
Pérdida por incumplimiento (bruta)	-\$842,400
Costo de seguros de vida (1.5% del monto)	-\$363,195
RESULTADOS	
ROE (Retorno sobre capital)	14.58%
Profit promedio por préstamo aprobado	\$757
Profit neto total	\$3,530,740

Nota: Los acreditados en default pagaron en promedio el 48% del crédito antes de incumplir. Las tasas incluyen prima país México (+3.5 pp sobre tasas base LendingClub).

Adicionalmente, el análisis de sensibilidad sobre el umbral de aprobación identificó que el punto óptimo de maximización del profit se ubica en PD < 60%, con un profit proyectado de

Python, reduciendo el tiempo de decisión a segundos una vez que el solicitante introduce sus variables, eliminando también el costo del analista humano por expediente.

Conversión de usuarios. El umbral operativo de $PD < 30\%$ (grados A–E) aprueba el 46.6% de las solicitudes simuladas, frente a la práctica habitual de operadores como Kueski o Alivio Capital, que aplican criterios más restrictivos o genéricos sin scoring diferenciado por tipo de procedimiento. Al asignar tasas diferenciadas por grade en lugar de una tasa fija, el modelo permite aprobar perfiles que serían rechazados bajo un esquema uniforme conservador, ampliando la base de clientes alcanzable sin incrementar el riesgo de la cartera.

Rentabilidad del portafolio. La simulación masiva de 10,000 solicitudes arrojó un profit neto total de \$3,530,740 USD, un ROE de 14.58% y una tasa de mora efectiva de 3.6%, inferior al benchmark nacional de 4.5% reportado para el primer semestre de 2025 (EGADE, 2025). El análisis de sensibilidad identificó que, bajo un umbral más permisivo de $PD < 60\%$, el profit proyectado asciende a \$6,922,627 USD con un ROE de 15.54%, aunque a costa de un mayor riesgo en cartera. La selección del umbral óptimo queda sujeta al apetito de riesgo institucional.

B. Evaluación de Triple Impacto

Impacto financiero. El modelo genera valor cuantificable para la institución prestamista a través de un spread diferenciado, comisiones de apertura y la protección parcial del seguro de vida (prima del 1.5% del monto, con costo total de \$363,195 USD en la simulación). El esquema de pago directo al hospital o médico elimina el riesgo moral sobre el destino de los recursos, un riesgo frecuente en créditos personales genéricos.

Impacto social. De acuerdo con datos de la ISAPS, en 2022 se reportaron 14,986,982 procedimientos quirúrgicos a nivel mundial, con un incremento de 16.7% respecto a 2021, ubicando a México en el cuarto lugar mundial con 938,096 procedimientos. A pesar de este dinamismo, los seguros de gastos médicos mayores excluyen sistemáticamente los procedimientos estéticos, dejando a los pacientes sin opciones de financiamiento estructuradas. El modelo democratiza el acceso a estos procedimientos para personas físicas con capacidad de pago demostrable pero sin liquidez inmediata, especialmente relevante en Guadalajara, principal destino de turismo médico del país con costos 40–80% inferiores a los de Estados Unidos. Adicionalmente, el seguro de vida vinculado a cada operación proporciona protección real a las familias de los acreditados: entre 2014 y 2025 se documentaron al menos 121 fallecimientos por cirugías estéticas en México, con un máximo de 22 casos en 2023 (Animal Político/CONNECTAS, 2026), un riesgo que los modelos de crédito genérico ignoran por completo.

Impacto ambiental. La digitalización íntegra del proceso de evaluación y aprobación elimina el uso de papel en el expediente crediticio. Un proceso manual típico genera entre 15 y 30 páginas por expediente. Proyectando esto sobre las 4,662 solicitudes aprobadas en la simulación, la

automatización evita la impresión y archivo de entre 69,930 y 139,860 páginas por ciclo de originación, además de eliminar los desplazamientos físicos del solicitante a sucursales bancarias: considerando un recorrido promedio de 8 km por visita y el factor de emisión de 0.21 kg CO₂/km de un automóvil promedio, se estima una reducción de aproximadamente 7,832 kg de CO₂ por ciclo de originación.

VI. CONCLUSIONES

Los dos modelos que se probaron (Regresión Logística y Random Forest) llegaron exactamente al mismo resultado: AUC de 0.8587, Gini de 0.72 y KS de 0.56. Eso dice algo importante: el problema de predecir si alguien va a incumplir un crédito de consumo no garantizado no requiere un modelo sofisticado, porque la información disponible ya tiene un límite natural de predictibilidad. Agregar complejidad no compra más precisión. Por eso, si este modelo se implementara en una institución financiera real regulada por la CNBV, la Regresión Logística sería la opción correcta: explica con claridad por qué se aprueba o rechaza a alguien, lo cual es un requisito legal, no solo una preferencia técnica.

Una advertencia importante sobre las probabilidades que produce el modelo: el ajuste que se hizo para que el modelo vea por igual a buenos y malos pagadores tiene un efecto secundario. Las probabilidades absolutas quedan infladas; el modelo predice una tasa de default promedio del 39% cuando en realidad es del 22%. Eso no importa para decidir quién es más riesgoso que quién, que es exactamente para lo que se usa el modelo, pero sí importaría si alguien quisiera usar esas probabilidades para cálculos regulatorios de capital. En producción habría que calibrarlas.

El LGD promedio de 0.9437 y la mediana exacta de 1.0 no son resultados fallidos, son la realidad del crédito al consumo sin garantía. Cuando alguien deja de pagar un préstamo personal, la institución no tiene nada que embargar. La mayoría de las veces la pérdida es total. Los modelos de regresión que se entrenaron para predecir el LGD individual obtuvieron un R² prácticamente de cero, lo que significa que no añaden información útil más allá del promedio. La decisión correcta fue usar ese promedio directamente en lugar de fingir que el modelo individual predice algo. Esto tiene una implicación de negocio directa: como la pérdida en default siempre es casi total, la única forma de que el modelo sea rentable es rechazar a tiempo a quienes tienen alta probabilidad de incumplir, no intentar recuperar después. La puerta de entrada lo es todo.

El ajuste de +3.5 puntos porcentuales sobre las tasas de LendingClub no es un número arbitrario. Refleja que el dinero en México cuesta más que en Estados Unidos, que es donde se entrenó el modelo. Sin ese ajuste, la institución estaría prestando a tasas que no cubren su costo de fondeo real. El seguro de vida proporcional al 1.5% del monto también tiene una lógica clara: si el riesgo que asume la aseguradora es el saldo pendiente, y ese saldo es proporcional al crédito, la prima debe serlo también.

La simulación de 10,000 solicitudes con personas reales del dataset arroja algo relevante: con el umbral conservador de

PD < 30%, el 96.4% de los créditos aprobados se pagaron en su totalidad, produciendo una tasa de mora del 3.6%, por debajo del 4.5% que registra el mercado mexicano de crédito personal. El modelo logra armar una cartera más limpia que el promedio del mercado. El profit neto de USD 3.5 millones equivale a USD 757 de ganancia por cada crédito aprobado, proveniente principalmente de la combinación de intereses de los buenos pagadores más la comisión del 2% que se cobra desde el primer día.

El análisis de sensibilidad muestra que si se relaja el umbral hasta PD < 60%, el profit casi se duplica a USD 6.9 millones. Pero eso no significa que ese umbral sea el correcto para operar: aprobar perfiles con PD del 50% implica que uno de cada dos clientes va a incumplir, lo cual es devastador para la reputación de la institución y para el capital regulatorio requerido. El umbral que se elija al final depende de cuánto riesgo puede absorber la institución, no del modelo.

Finalmente, el modelo fue entrenado con préstamos de Estados Unidos entre 2007 y 2015, en plena crisis financiera global. La tasa de default del 22% que el modelo aprendió es más alta de lo normal, y los patrones de comportamiento crediticio pueden ser distintos a los del mercado mexicano actual. Todo modelo de crédito necesita reentrenarse con datos propios lo antes posible.

La Prensa. (2024, septiembre 12). *México, el cuarto lugar en procedimientos estéticos a nivel mundial*. OEM. <https://oem.com.mx/la-prensa/mexico/mexico-el-cuarto-lugar-en-procedimientos-esteticos-a-nivel-mundial-13099862>

VII. BIBLIOGRAFIA

Adarsh Sng. (s. f.). *Lending Club Loan Data CSV* [Conjunto de datos]. Kaggle. Recuperado el 13 de mayo de 2026, de [Kaggle Dataset](#)

ISAPS – International Society of Aesthetic Plastic Surgery. (2025). ISAPS Global Statistics 2024. <https://www.isaps.org/medical-professionals/isaps-global-statistics/>

Dr. Arturo Valdez Clínica. (s.f.). Costo de la cirugía plástica en México. <https://drarturovaldez.com/es/costo-de-la-cirugia-plastica-en-mexico/>

SoFi. (s.f.). Plastic surgery financing: Common cosmetic procedures and their average costs. <https://www.sofi.com/learn/content/plastic-surgery-financing/#common-cosmetic-procedures-and-their-average-costs>

Animal Político / CONNECTAS. (2026). Sin registro oficial: las muertes por cirugías plásticas en México. <https://grupoanimal.mx/salud/muertes-cirugias-plasticas-sin-registro-mexico>

EGADE Business School. (2025). El crédito se enfría, pero la morosidad se contiene. <https://egade.tec.mx/es/egade-ideas/opinion/el-credito-se-enfria-pero-la-morosidad-se-contiene-senales-para-tu-negocio>